PRÉPARATION À LA SOUTENANCE · PFE DATA SCIENCE

Questions du jury et réponses argumentées

Système décisionnel intelligent et moteur de recommandation pour l'agence 2 Go Sunny Tunisia Trip — application TravelBI

87 questions réparties en 12 thèmes, avec leur niveau de probabilité et des conseils

Ranim Nabi
ESPRIT · Année universitaire 2025-2026

MODE D'EMPLOI

Comment utiliser ce document

Les questions sont regroupées par thème et suivent l'ordre de la présentation. Chacune porte un niveau :

TRÈS PROBABLE	Question posée dans la plupart des soutenances : réponse à connaître par cœur.
PROBABLE	Question fréquente selon le profil du jury (technique, métier, méthodologie).
QUESTION PIÈGE	Question qui vise une faiblesse ou une incohérence du projet : à préparer avec le plus de soin.

Les réponses s'appuient sur les résultats réels du notebook, du rapport et de l'application. Les encadrés « Conseil » indiquent comment répondre et, le cas échéant, ce qu'il faut vérifier avant la soutenance.

SOMMAIRE

Comment utiliser ce document . . . 2
Fiche mémo : les chiffres clés . . . 3
Présentation générale du projet . . . 4
Organisme d'accueil et existant . . . 5
Méthodologie : Scrum et CRISP-DM . . . 6
Les données . . . 8
Préparation des données et segmentation . . . 10
Informatique décisionnelle et Power BI . . . 12
Le moteur de recommandation . . . 14
Évaluation et validité des résultats . . . 17
L'application TravelBI et le déploiement . . . 19
Architecture, conception et technologies . . . 21
Sécurité, éthique et données personnelles . . . 22
Limites, perspectives et bilan . . . 23

À RETENIR

Fiche mémo : les chiffres clés

Ces chiffres reviennent dans de nombreuses réponses. Les citer avec précision renforce immédiatement la crédibilité.

Organisme	2 Go Sunny Tunisia Trip, Monastir ; directeur M. Adel Nabi
Encadrement	ESPRIT : M. Sirajeddine Miladi (et Mme Zoulaikha Ouali) ; agence : M. Kamel Kharrat
Données	500 clients, 45 destinations, 135 hôtels, 90 vols, 9 944 réservations (9 916 après nettoyage)
Données réelles	11 clients et 16 réservations ; le reste est augmenté
Nettoyage	28 doublons, 444 montants aberrants écrêtés (IQR), 13,27 % de notes manquantes
Indicateurs	CA 36,8 M TND (≈ 37 M) ; 8 597 confirmées ; panier 4 284 TND ; annulation 13,30 %
Interactions	4 802 couples client × destination ; matrice remplie à 21,3 %
Découpage	80/20 par client : 3 644 entraînement, 1 158 test ; 499 clients évalués ; K = 7
Segmentation	KMeans, k = 5, sur 6 variables standardisées
Modèle retenu	Hybride : 0,2 contenu + 0 MF + 0,5 LightGBM + 0,3 popularité
Performance	HitRate@7 = 0,85 ; NDCG@7 = 0,461 (+4,1 % vs LightGBM) ; objectif 0,70
Application	TravelBI, PyQt6, exécutable Windows (PyInstaller) ; contrôle 40/40 clients identiques

SIX RÈGLES POUR RÉPONDRE

Commencer par la réponse

Donnez la réponse en une phrase, puis justifiez. Le jury décroche si la conclusion arrive à la fin.

Chiffrer

Un chiffre précis (85 %, 4 802 interactions, 40/40) vaut mieux qu'un long discours. Gardez la fiche mémo en tête.

Assumer les limites

Sur les données générées ou les biais d'évaluation, reconnaissez la limite, expliquez son effet, proposez la correction.

Ne jamais inventer

Si vous ne savez pas : « Je ne l'ai pas mesuré ; voici comment je le ferais. » C'est une réponse d'ingénieur.

Renvoyer au rapport

Pour un détail technique, citez la section du rapport : cela montre la maîtrise de votre document.

Rester brève

Trente à soixante secondes par réponse. Le jury relancera s'il veut plus de détails.

THÈME 01

Présentation générale du projet

5 questions

Q1 Présentez votre projet en une minute.

TRÈS PROBABLE

J'ai conçu pour l'agence 2 Go Sunny Tunisia Trip un système décisionnel qui répond à deux besoins : piloter l'activité et conseiller chaque client. Les données de l'agence sont nettoyées et organisées dans un modèle en étoile exploité par un rapport Power BI de cinq pages. Un moteur de recommandation hybride propose à chaque client un Top-N de destinations expliqué, y compris à un nouveau client. L'ensemble est réuni dans une application de bureau, TravelBI. Le moteur retenu atteint un HitRate@7 de 85 %, au-delà de l'objectif de 70 %.

Conseil : Préparez ce pitch par cœur : il sert aussi de réponse à « Quelle est votre contribution ? ».

Q2 Quelle est la problématique de votre projet ?

TRÈS PROBABLE

Comment transformer les données dispersées d'une agence de voyages en un outil d'aide à la décision qui fournit des indicateurs fiables et recommande à chaque client les destinations les plus pertinentes, même lorsqu'il n'a pas d'historique ?

Q3 Quelle est votre contribution personnelle ?

TRÈS PROBABLE

J'ai mené le projet de bout en bout : analyse du besoin, préparation des données, construction du modèle en étoile et du rapport Power BI, implémentation et comparaison de sept variantes de recommandation (dont une factorisation matricielle écrite moi-même en NumPy), conception du modèle hybride, puis développement de l'application TravelBI avec son contrôle de cohérence automatique.

Conseil : Citez des éléments concrets que vous avez écrits vous-même : la factorisation matricielle, le module moteur_reco.py, le contrôle selfcheck.

Q4 Pourquoi ce sujet est-il pertinent pour une agence de voyages ?

PROBABLE

Le voyage est un achat rare, coûteux et très personnel : le conseil fait la différence face aux plateformes en ligne. Une petite agence ne peut pas s'offrir les systèmes de Booking.com ou d'Airbnb, mais elle possède ses propres données. Le projet lui donne, à faible coût, à la fois un outil de pilotage et un outil de conseil.

Q5 Quels sont les livrables du projet ?

PROBABLE

Un notebook Python reproductible (préparation, modèles, exports) ; un modèle en étoile et sept tables de KPI ; un rapport Power BI de cinq pages publié sur Power BI Service ; l'application TravelBI (code source et exécutable Windows) ; le rapport de PFE.

THÈME 02

Organisme d'accueil et existant

4 questions

Q6 Comment fonctionnait l'agence avant votre projet ?

PROBABLE

Le client contacte l'agence par Facebook ou par téléphone, l'agent propose des destinations selon son expérience, la réservation est enregistrée, mais aucun indicateur n'est suivi. Les données existent dans plusieurs tables (clients, hôtels, vols, forfaits, réservations) sans être reliées ni exploitées.

Q7 Quelles sont les limites de l'existant ?

PROBABLE

Une vision client fragmentée, un conseil qui dépend de l'agent présent et n'est pas reproductible, l'absence de pilotage (chiffre d'affaires, annulations, saisonnalité invisibles) et, au final, des opportunités commerciales manquées : pas de relance ciblée ni de fidélisation.

Q8 Vous dites que l'agence n'a pas de site web, mais vos données contiennent un canal « Site web » qui pèse 43 % des réservations. Comment l'expliquez-vous ?

QUESTION PIÈGE

Les canaux de vente proviennent des données augmentées : le générateur a attribué à chaque réservation l'un des quatre canaux standards d'une agence (agence physique, site web, application mobile, centre d'appels). Ce champ ne reflète donc pas la réalité commerciale actuelle de l'agence. Les analyses par canal démontrent la capacité du système à suivre ces canaux dès qu'ils existeront, mais leurs valeurs ne doivent pas être interprétées commercialement.

Conseil : Reconnaissez l'écart immédiatement ; ne tentez pas de le justifier autrement. Adaptez la réponse si l'agence dispose en réalité d'autres canaux.

Q9 Avez-vous réalisé un état de l'art ou un benchmark ?

PROBABLE

Oui : j'ai étudié les familles de systèmes de recommandation (contenu, collaboratif, connaissance, hybride), les spécificités du tourisme (achats rares, contexte, démarrage à froid fréquent), les pratiques de Booking.com et d'Airbnb, et comparé Power BI, Tableau et Qlik Sense. Ce travail justifie le choix d'un modèle hybride et de Power BI.

THÈME 03

Méthodologie : Scrum et CRISP-DM

6 questions

Q10 Pourquoi avoir combiné Scrum et CRISP-DM ?

TRÈS PROBABLE

Parce que le projet mêle deux natures de travail. Les livrables logiciels (tableaux de bord, application) se construisent bien par incréments validés régulièrement : c'est Scrum. Le travail sur les données exige de comprendre, préparer, modéliser et évaluer avant de déployer : c'est CRISP-DM. Aucune des deux ne couvre seule l'ensemble ; les phases de CRISP-DM se répartissent sur les quatre sprints.

Q11 Comment avez-vous appliqué Scrum alors que vous étiez seule ?

TRÈS PROBABLE

Les rôles ont été adaptés : la direction de l'agence et l'encadrant professionnel jouent le rôle de Product Owner, l'encadrant académique celui de Scrum Master, et j'ai constitué l'équipe de développement. Le projet a été découpé en quatre sprints avec un carnet de produit de quatorze récits utilisateurs priorisés (MoSCoW), une définition de « terminé » par sprint, une revue et une rétrospective à la fin de chaque sprint.

Conseil : Soyez honnête : c'est un Scrum adapté. Le jury l'accepte s'il voit les artefacts (carnet, critères de validation, revues).

Q12 Détaillez vos sprints.

TRÈS PROBABLE

Sprint 1 : compréhension et préparation des données (CRISP-DM 1 à 3). Sprint 2 : modèle en étoile et rapport Power BI. Sprint 3 : moteur de recommandation, avec comparaison de sept variantes (CRISP-DM 4 et 5). Sprint 4 : export des modèles, application TravelBI et exécutable (CRISP-DM 6). Chaque sprint avait un critère de validation, par exemple « HitRate@7 ≥ 0,70 » pour le sprint 3.

Conseil : Donnez les durées réelles de vos sprints si le jury les demande.

Q13 Donnez un exemple de rétrospective qui a modifié votre travail.

PROBABLE

Après le sprint 3, j'ai décidé d'exporter les boosters dans leur format natif plutôt qu'avec joblib, pour que l'application reste utilisable quelle que soit la version des bibliothèques, et d'exporter des recommandations de référence pour vérifier automatiquement l'application. Le premier moteur fondé sur LightGBM seul a aussi été complété par XGBoost, CatBoost et un signal de popularité.

Q14 Quelles sont les six phases de CRISP-DM ?

PROBABLE

Compréhension du métier, compréhension des données, préparation des données, modélisation, évaluation et déploiement. Le processus est itératif : l'évaluation peut renvoyer à la préparation ou à la modélisation.

Q15 Pourquoi pas une méthode en cascade ?

PROBABLE

Les résultats d'un modèle ne sont connus qu'après expérimentation : une planification figée aurait mal absorbé les retours en arrière (ajout de boosters, nouveaux signaux). Les sprints ont permis de livrer tôt des résultats utilisables (tableaux de bord) et d'ajuster le moteur au fil des revues.

THÈME 04

Les données

9 questions

Q16 D'où viennent vos données ?

TRÈS PROBABLE

Des tables de l'agence : clients, hôtels, vols et tarifs, forfaits, réservations, ainsi que les tables géographiques (villes, pays, continents). L'historique réel étant très réduit (11 clients, 16 réservations), ces données ont été augmentées pour atteindre 500 clients et près de 10 000 réservations.

Q17 Vos données sont presque toutes générées. Vos résultats ont-ils une valeur ?

TRÈS PROBABLE

Ils ont une valeur méthodologique et technique, pas encore une valeur commerciale définitive. La chaîne complète (préparation, BI, moteur, application) est opérationnelle et sera directement utilisable sur l'historique réel. Les performances mesurées, en revanche, reflètent en partie les règles de génération : elles devront être confirmées sur les vraies réservations. C'est la première limite identifiée dans mon rapport, et la première perspective.

Conseil : C'est LA question la plus probable. Répondez calmement, sans minimiser : le jury valorise la lucidité.

Q18 Comment avez-vous augmenté les données ?

TRÈS PROBABLE

Avec trois techniques : le rééchantillonnage (bootstrap) des enregistrements réels, une perturbation contrôlée des valeurs numériques (montants, dates), et une génération conditionnée par six segments latents (aventurier, farniente, culturel, luxe, familial, budget) qui orientent le type de voyage préféré et le budget. Les données restent ancrées dans le réel : mêmes villes, mêmes hôtels, mêmes tarifs. Une colonne « source » indique l'origine de chaque ligne.

Q19 Le moteur a-t-il simplement réappris les règles du générateur ?

QUESTION PIÈGE

C'est un risque réel. La génération conditionnée par segment introduit des régularités que les modèles peuvent retrouver, ce qui peut gonfler les performances. C'est pourquoi je présente le HitRate@7 de 85 % comme une borne haute. La seule vraie réponse est une évaluation sur l'historique réel, puis un test en conditions réelles.

Q20 Quels problèmes de qualité avez-vous rencontrés ?

PROBABLE

Des valeurs manquantes (notes de satisfaction 13,27 %, canal 1,21 %, nombre de personnes 0,79 %, montant 0,60 %), 28 doublons exacts, des nombres de voyageurs impossibles et 444 montants aberrants. Les notes manquantes sont en grande partie normales : une réservation annulée n'est pas notée.

Q21 Comment avez-vous traité les valeurs manquantes ?

PROBABLE

Imputation par le mode pour le canal (variable catégorielle) et par la médiane pour le nombre de personnes et le montant, car la médiane est robuste aux valeurs extrêmes. Les notes de satisfaction des réservations annulées sont laissées vides. Dans le score d'interaction, une note absente est remplacée par la valeur neutre 3.

Q22 Pourquoi la méthode IQR et pourquoi écrêter plutôt que supprimer ?

PROBABLE

La méthode de l'écart interquartile ne suppose pas de distribution normale, ce qui convient à des montants asymétriques. Une valeur hors de [Q1 − 1,5 IQR ; Q3 + 1,5 IQR] est jugée aberrante. J'ai choisi d'écrêter (ramener à la borne) pour conserver la réservation, qui reste une information valide, tout en limitant l'influence du montant extrême sur les indicateurs et les modèles.

Q23 Certaines réservations ont une date de départ dans le futur. Est-ce normal ?

QUESTION PIÈGE

504 réservations partent après la date de référence du 15 septembre 2026. Ce sont des réservations à venir, légitimes pour une agence, mais elles posent deux problèmes : des récences négatives et un chiffre d'affaires « confirmé » qui inclut des voyages non encore effectués. La correction consiste à fixer la date de référence à la date d'export et à distinguer réservations réalisées et à venir. C'est la limite L2 de mon rapport.

Q24 Vos clients s'appellent Emilia Clarke, Sherlock Holmes… Ce sont de vrais clients ?

QUESTION PIÈGE

Les identités des clients sont des pseudonymes : les noms réels ne figurent pas dans les données utilisées, ce qui protège la vie privée des clients de l'agence. Seuls les attributs utiles à l'analyse (âge, ville, revenu, préférences, réservations) sont exploités.

Conseil : *Vérifiez avant la soutenance que c'est bien le cas et adaptez la réponse si les noms ont une autre origine.*

THÈME 05

Préparation des données et segmentation

7 questions

Q25 Qu'est-ce que l'analyse RFM et pourquoi l'utiliser ?

TRÈS PROBABLE

RFM signifie récence (jours depuis le dernier voyage), fréquence (nombre de réservations) et montant (total et moyen dépensé). C'est une méthode classique de marketing pour décrire la valeur et l'engagement d'un client. Je l'ai complétée par le taux d'annulation individuel. Ces variables servent à la segmentation et au modèle supervisé.

Q26 Comment avez-vous représenté les clients et les destinations ?

PROBABLE

Par des vecteurs de 20 dimensions dans le même espace : 7 composantes pour le type de voyage (one-hot), 12 pour les activités (multi-hot) et une pour le budget normalisé par 20 000 TND. Pour le client, on prend ses préférences déclarées ; pour la destination, ses caractéristiques. La similarité cosinus entre ces vecteurs donne le score de contenu.

Q27 Comment avez-vous construit la variable cible, alors qu'il n'y a pas de notes explicites ?

TRÈS PROBABLE

J'ai construit un score d'interaction implicite de 0 à 5 pour chaque réservation confirmée : 45 % pour la note de satisfaction, 25 % pour la récence, 20 % pour le montant normalisé et 10 % de bonus pour le fait d'avoir réservé. On garde le score maximal par couple client-destination, ce qui donne 4 802 interactions.

Conseil : Si on vous demande pourquoi ces poids : ils traduisent un jugement métier (la satisfaction prime), non optimisé. C'est un choix à assumer, et une piste d'amélioration.

Q28 Pourquoi KMeans et pourquoi k = 5 ?

PROBABLE

KMeans est simple, rapide et produit des centres interprétables, ce qui convient à une segmentation marketing. Les six variables (âge, revenu, fréquence, montant, récence, taux d'annulation) sont standardisées pour qu'aucune ne domine. Le nombre de segments a été choisi par la méthode du coude, qui montre une inflexion de l'inertie autour de cinq.

Q29 Avez-vous validé la qualité de la segmentation ?

PROBABLE

Par la méthode du coude et par l'interprétabilité métier des segments : fidèles à forte valeur, réguliers, réguliers et fiables, clients à forte annulation, inactifs. Je n'ai pas calculé d'indice de silhouette ; ce serait un complément utile pour confirmer le choix de k.

Conseil : Ne prétendez pas avoir fait une validation que vous n'avez pas faite ; proposez-la comme amélioration.

Q30 Quels sont vos segments et à quoi servent-ils ?

PROBABLE

Segment 3 : 108 clients fidèles à forte valeur (26 réservations en moyenne), à fidéliser. Segments 0 et 2 : clients réguliers, le 2 étant très fiable (8 % d'annulation). Segment 1 : 96 clients à forte annulation (23 %), dont il faut sécuriser les réservations (acompte, rappel). Segment 4 : 52 clients inactifs depuis environ 257 jours, à relancer.

Q31 À quoi sert l'ACP dans votre projet ?

PROBABLE

Uniquement à la visualisation : elle projette les six variables sur deux axes pour afficher les segments sur un graphique. Elle n'est pas utilisée pour former les segments.

THÈME 06

Informatique décisionnelle et Power BI

9 questions

Q32 Expliquez votre modèle en étoile.

TRÈS PROBABLE

Une table de faits, fact_reservations, dont le grain est la réservation, contient les mesures (montant, nombre de personnes, nuits, note) et les clés vers quatre dimensions : clients, destinations, hôtels et vols, plus une dimension calendrier Dim_Dates créée dans Power BI. Ce modèle simplifie les requêtes, accélère les agrégations et se lit facilement par les utilisateurs métier.

Q33 Quelle différence entre un modèle en étoile et un modèle en flocon ?

PROBABLE

Dans l'étoile, chaque dimension est une table unique reliée directement aux faits. Dans le flocon, les dimensions sont normalisées en sous-tables. Mon modèle est principalement en étoile ; la relation entre hôtels et destinations introduit une légère tendance au flocon.

Q34 Quels indicateurs avez-vous définis et comment ?

TRÈS PROBABLE

Chiffre d'affaires : somme des montants des réservations confirmées. Nombre de réservations. Panier moyen : montant moyen d'une réservation confirmée. Taux d'annulation : réservations annulées sur l'ensemble des réservations. Satisfaction moyenne, clients actifs, revenu moyen par client, et une évolution par rapport au mois précédent. Ils sont calculés en DAX dans une table de mesures.

Q35 Donnez un exemple de mesure DAX.

PROBABLE

CA Total = CALCULATE(SUM(fact_reservations[montant_total_tnd]), fact_reservations[statut_reservation] = "Confirmée"). Pour l'évolution mensuelle : CA Mois Précédent = CALCULATE([CA Total], DATEADD(Dim_Dates[Date], -1, MONTH)), puis Évolution CA % = DIVIDE([CA Total] − [CA Mois Précédent], [CA Mois Précédent]).

Conseil : Récitez les formules réelles de votre fichier .pbix, et sachez expliquer CALCULATE (changement du contexte de filtre) et DIVIDE (division protégée contre zéro).

Q36 Pourquoi une table calendrier ?

PROBABLE

Les fonctions de temps de DAX, comme DATEADD, nécessitent une table de dates continue, marquée comme table de dates. Elle fournit aussi les colonnes année, trimestre, mois et nom du mois utilisées par les filtres et les axes.

Q37 Sur la page « Saisonnalité et canaux », les quatre canaux affichent la même valeur. Pourquoi ?

QUESTION PIÈGE

Ces visuels utilisent comme axe la colonne canal de la table kpi_taux_annulation, alors que la mesure est calculée sur fact_reservations. Cette table se trouve du côté « plusieurs » de sa relation : le filtre posé sur le canal ne se propage pas jusqu'à la table de faits, et la mesure est calculée sur l'ensemble des canaux. La correction consiste à utiliser fact_reservations[canal_vente] comme axe. J'ai détecté cette anomalie en revue de sprint.

Conseil : Mieux : corrigez-la avant la soutenance et dites-le.

Q38 Pourquoi avoir des tables de KPI pré-agrégées en plus des mesures ?

PROBABLE

Elles ont permis de construire rapidement certains visuels à partir des exports du notebook. Mais elles créent des chemins de filtrage supplémentaires et sont redondantes avec les mesures ; l'anomalie des canaux en est la conséquence. À terme, il vaut mieux les remplacer par des mesures DAX pour revenir à une étoile stricte.

Q39 Comment avez-vous vérifié vos indicateurs ?

PROBABLE

En recalculant indépendamment, à partir de fact_reservations.csv, les quatre indicateurs de la page d'accueil : 36 832 329 TND de chiffre d'affaires, 8 597 réservations confirmées, 4 284 TND de panier moyen et 13,30 % d'annulation, tous identiques à Power BI. Les indicateurs 2026 de l'application ont été vérifiés de la même façon.

Q40 Pourquoi Power BI plutôt que Tableau ou Qlik ?

PROBABLE

Power BI Desktop est gratuit en phase de conception, importe directement les CSV du notebook, propose DAX pour les calculs et permet de publier un rapport puis de l'intégrer dans une application tierce. Tableau et Qlik sont plus coûteux pour une petite agence.

THÈME 07

Le moteur de recommandation

13 questions

Q41 Quelles approches de recommandation avez-vous comparées ?

TRÈS PROBABLE

Quatre familles, soit sept variantes : filtrage fondé sur le contenu (similarité cosinus), filtrage collaboratif par factorisation matricielle, trois modèles supervisés de gradient boosting (LightGBM, XGBoost, CatBoost) et leur moyenne, puis un modèle hybride qui combine les signaux.

Q42 Expliquez la factorisation matricielle.

TRÈS PROBABLE

On approxime la matrice client × destination par le produit de deux matrices de faibles dimensions : chaque client et chaque destination reçoivent un vecteur latent de 20 dimensions. Le score prédit vaut $\mu + b_u + b_i + p_u \cdot q_i$, avec la moyenne globale, un biais client et un biais destination. Les paramètres sont appris par descente de gradient stochastique, avec régularisation (pas 0,015, régularisation 0,06, 40 époques). Je l'ai implémentée moi-même en NumPy.

Q43 Pourquoi avoir implémenté la factorisation « from scratch » ?

PROBABLE

Pour maîtriser entièrement l'algorithme, contrôler l'export des vecteurs latents vers l'application sans dépendance supplémentaire, et démontrer la compréhension du mécanisme (fonction de coût, gradient, régularisation) plutôt que l'appel d'une bibliothèque.

Q44 Comment fonctionne votre modèle supervisé ?

TRÈS PROBABLE

Le problème est reformulé en régression : prédire le score d'un couple client-destination à partir de 14 variables (7 du client, 4 de la destination, 4 croisées : similarité cosinus, correspondance du type de voyage, activités communes, rapport de budget). Les 3 644 interactions d'entraînement sont les exemples positifs ; on y ajoute deux fois plus d'exemples négatifs tirés au hasard, soit 10 932 lignes.

Q45 Pourquoi des exemples négatifs, et pourquoi l'étiquette 0,3 ?

PROBABLE

Sans négatifs, le modèle ne verrait que des destinations réservées et ne saurait pas distinguer le pertinent du non pertinent. L'étiquette 0,3 plutôt que 0 traduit l'incertitude : une destination non réservée n'est pas forcément rejetée, le client ne la connaissait peut-être pas. C'est un choix heuristique ; un échantillonnage des négatifs selon la popularité serait plus rigoureux.

Q46 Qu'est-ce que le gradient boosting ?

PROBABLE

Une méthode d'ensemble qui construit des arbres de décision successifs, chacun corrigeant les erreurs des précédents en suivant le gradient de la fonction de perte. LightGBM, XGBoost et CatBoost en sont trois implémentations performantes sur des données tabulaires.

Q47 Comment avez-vous réglé les hyperparamètres ?

PROBABLE

Par recherche aléatoire avec validation croisée : 12 tirages sur 3 plis pour LightGBM, 40 sur 5 plis pour XGBoost, 15 sur 5 plis pour CatBoost. Les erreurs de validation sont très proches (1,284 à 1,298) ; le booster intégré au modèle hybride a donc été choisi sur la qualité du classement, et c'est LightGBM qui l'emporte.

Q48 Comment fonctionne le modèle hybride ?

TRÈS PROBABLE

Il combine quatre signaux ramenés sur 0 à 5 : score = 0,2 × contenu + 0 × factorisation + 0,5 × LightGBM + 0,3 × popularité, borné à [0 ; 5]. Les poids ont été cherchés sur une grille de 286 combinaisons au pas de 0,1, en maximisant le NDCG@7. Les destinations déjà réservées sont exclues, puis les N meilleures sont retournées avec une explication.

Q49 Pourquoi le poids de la factorisation matricielle est-il nul ?

TRÈS PROBABLE

Parce que, sur ces données, le signal collaboratif n'améliore pas le classement une fois les autres signaux présents. Chaque client n'a en moyenne que 9,6 destinations réservées et la matrice n'est remplie qu'à 21 % : le signal est faible et redondant avec la popularité et le booster. C'est un résultat en soi, cohérent avec la littérature sur le tourisme où l'historique par client est rare.

Q50 Comment gérez-vous un nouveau client sans historique (démarrage à froid) ?

TRÈS PROBABLE

Son profil est construit à partir des informations saisies : âge, revenu, type de voyage préféré, activités et budget. Le score de contenu utilise ce profil déclaré, le booster reçoit des variables d'historique neutres (fréquence nulle, récence de 9 999 jours), la composante collaborative se réduit au biais de la destination, et la popularité joue son rôle d'a priori. Le client reçoit donc des propositions dès sa première visite.

Q51 Comment les recommandations sont-elles expliquées ?

TRÈS PROBABLE

Par des règles qui comparent le profil du client et la destination : correspondance du type de voyage, activités communes, budget moyen compatible (au plus 10 % au-dessus du budget du client), popularité d'au moins 70 sur 100, satisfaction moyenne d'au moins 4,2. Ces critères reprennent les variables importantes du modèle. L'explication sert d'argument de vente au conseiller.

Conseil : Si on vous parle de SHAP : ces explications sont des règles métier, pas une décomposition exacte de la prédiction. SHAP serait une amélioration pour expliquer fidèlement la part du booster.

Q52 Quelles variables comptent le plus pour LightGBM ?

PROBABLE

La note moyenne et le budget moyen de la destination, la fréquence du client, la popularité, le nombre de réservations de la destination et le montant moyen du client. Les variables croisées (similarité, correspondance de type, rapport de budget) viennent ensuite.

Q53 Pourquoi un score de recommandation autour de 2 sur 5 seulement ?

PROBABLE

Les exemples négatifs étiquetés 0,3 tirent les prédictions du booster vers le bas, et la combinaison pondérée hérite de cette échelle. Seul l'ordre relatif est utilisé pour recommander ; la valeur absolue n'est pas une probabilité et ne doit pas être présentée comme telle au client.

THÈME 08

Évaluation et validité des résultats

10 questions

Q54 Comment avez-vous évalué le moteur ?

TRÈS PROBABLE

Pour chaque client ayant au moins deux interactions, 20 % sont mises de côté pour le test (leave-k-out) : 3 644 interactions d'entraînement et 1 158 de test. Une interaction est pertinente si son score atteint 3 sur 5 ; 499 clients sont évaluables. Chaque modèle produit un Top-7 de destinations non réservées, évalué avec Precision, Recall, MAP, NDCG, HitRate au rang 7 et le RMSE.

Q55 Qu'est-ce que le NDCG ?

TRÈS PROBABLE

Le Normalized Discounted Cumulative Gain mesure la qualité d'un classement : une destination pertinente rapporte plus de points lorsqu'elle est placée en haut de la liste, avec une décroissance logarithmique selon le rang. Le résultat est divisé par la valeur d'un classement idéal, pour obtenir un score entre 0 et 1.

Q56 Que signifie un HitRate@7 de 85 % ?

TRÈS PROBABLE

Pour 85 % des clients évalués, la liste de sept destinations proposée contient au moins une destination qu'ils ont effectivement appréciée. C'est la métrique la plus proche de l'expérience du client et du conseiller.

Q57 Pourquoi K = 7 ?

PROBABLE

Sept propositions correspondent à ce qu'un conseiller peut présenter lors d'un entretien. De plus, un client n'a que peu de destinations pertinentes dans le test : la Precision@K est mécaniquement plafonnée bien en dessous de 1, même pour un modèle parfait. Le HitRate et le NDCG, qui n'ont pas ce plafond, sont donc les métriques de décision.

Q58 Votre Precision@7 n'est que de 0,195. N'est-ce pas faible ?

QUESTION PIÈGE

Elle est structurellement plafonnée : le test compte en moyenne environ 2,3 destinations pertinentes par client, donc même un modèle parfait ne dépasserait pas une Precision@7 d'environ 0,32. Il faut la comparer entre modèles (le modèle hybride est le meilleur) et la lire avec le Recall@7 de 0,58 et le HitRate@7 de 0,85.

Q59 La factorisation a le meilleur RMSE mais le pire classement. Pourquoi ?

TRÈS PROBABLE

Elle n'est entraînée que sur des interactions positives, dont les scores sont concentrés autour de 3,8 : elle prédit une valeur proche de cette moyenne pour tous les couples. L'erreur sur les couples du test est donc faible, mais les destinations ne sont pas distinguées entre elles. Cremonesi et al. (2010) ont montré ce phénomène : le meilleur RMSE ne donne pas le meilleur Top-N. C'est pourquoi le choix repose sur le NDCG et le HitRate.

Q60 Votre évaluation comporte-t-elle des biais ?

TRÈS PROBABLE

Oui, j'en ai identifié trois. Un biais de sélection : les poids hybrides et le booster ont été choisis sur le jeu de test, qui a donc servi à régler et à évaluer. Une fuite d'information : les variables RFM et de destination ont été calculées avant le découpage et contiennent une trace du test, ce qui avantage les modèles supervisés. Enfin, 97,6 % des interactions dépassent le seuil de 3, donc « pertinent » signifie presque « réservé ». Le taux de 85 % est donc une borne haute.

Conseil : Ne vous défendez pas : présentez ces biais comme une analyse critique que vous avez menée vous-même, avec les corrections.

Q61 Comment corrigeriez-vous ces biais ?

PROBABLE

Découper les interactions en trois parties (entraînement, validation pour les réglages, test pour l'évaluation finale) ; recalculer les variables RFM et de destination sur les seules interactions d'entraînement ; utiliser un seuil de pertinence plus discriminant ou une évaluation sur l'ensemble du catalogue ; idéalement, un découpage temporel qui prédit les réservations futures à partir du passé.

Conseil : Si vous avez corrigé le notebook avant la soutenance, présentez les nouveaux chiffres.

Q62 Pourquoi ne pas avoir fait un découpage temporel ?

PROBABLE

Le découpage aléatoire par client garantit que chaque client évalué a des interactions dans l'entraînement et le test. Un découpage temporel serait plus réaliste, car il reproduit l'usage réel (recommander le prochain voyage), et il réduirait la fuite d'information. C'est l'amélioration que je retiendrais en priorité avec des données réelles.

Q63 Comment savoir si le moteur apporte réellement des ventes ?

PROBABLE

L'évaluation hors ligne ne le dit pas. Il faut mesurer en conditions réelles : suivre le taux de conversion des destinations recommandées, puis mener un test A/B comparant des clients conseillés avec et sans le moteur. Booking.com a d'ailleurs montré qu'un gain hors ligne ne se traduit pas toujours en gain commercial.

THÈME 09

L'application TravelBI et le déploiement

9 questions

Q64 Pourquoi une application de bureau plutôt qu'une application web ?

TRÈS PROBABLE

L'agence n'a pas d'infrastructure serveur à maintenir. Une application de bureau fonctionne hors ligne pour les indicateurs et les recommandations, garde les données clients sur les postes de l'agence et se distribue en un exécutable Windows, sans installation de Python. Une version web reste une perspective si l'agence veut exposer les recommandations en ligne.

Q65 Votre première présentation parlait de Streamlit ; vous livrez une application PyQt6. Pourquoi ce changement ?

QUESTION PIÈGE

Streamlit permet un prototype rapide dans le navigateur, mais suppose de lancer un serveur Python. Pour un usage quotidien à l'agence, une application de bureau autonome était plus adaptée : exécutable Windows, fonctionnement hors ligne, intégration des rapports Power BI par Qt WebEngine. Le changement a été décidé en rétrospective de sprint.

Conseil : Adaptez si la raison réelle est différente.

Q66 Quelles sont les fonctionnalités de l'application ?

PROBABLE

Cinq sections : un tableau de bord annuel avec six indicateurs et leur variation ; les rapports Power BI intégrés, avec un mode présentation ; les recommandations pour un client existant ou un nouveau client, avec explication, décomposition du score et export CSV ; la performance des modèles ; et une page « À propos » avec le contrôle de cohérence et le rechargement des modèles.

Q67 Comment garantissez-vous que l'application reproduit le notebook ?

TRÈS PROBABLE

Le notebook exporte les recommandations de référence de 40 clients tirés au hasard. La fonction selfcheck recalcule leur Top-7 avec le moteur de l'application et vérifie que les listes sont identiques et que l'écart de score ne dépasse pas 0,01. Résultat : 40 sur 40 identiques, écart maximal 0,000.

Q68 Comment les modèles sont-ils transférés du notebook vers l'application ?

PROBABLE

La section 15 du notebook exporte un dossier TravelBI_App : le booster au format natif, les vecteurs latents de la factorisation, les vecteurs de profil, les variables des clients et des destinations, les métadonnées (poids, colonnes), les interactions, les données du tableau de bord et les références. Le module moteur_reco.py recharge ces artefacts sans réentraînement.

Q69 Pourquoi exporter les boosters au format natif plutôt qu'avec joblib ?

PROBABLE

Un fichier joblib dépend de la version exacte des bibliothèques Python : un changement de version peut le rendre illisible. Le format natif de LightGBM (texte), XGBoost (JSON) ou CatBoost reste lisible d'une version à l'autre, ce qui rend l'application plus robuste.

Q70 Comment met-on à jour les modèles ?

PROBABLE

On réexécute le notebook sur les nouvelles données, on remplace les dossiers models et data de l'application, puis on clique sur « Recharger les données et le modèle » et on lance le contrôle de cohérence. Aucune réinstallation n'est nécessaire.

Q71 Comment les rapports Power BI s'affichent-ils dans l'application ?

PROBABLE

Par un composant navigateur intégré, Qt WebEngine, qui ouvre le lien du rapport publié. L'application reconnaît les types de liens Power BI, conserve la liste des rapports dans config.json et bascule vers le navigateur si le composant est absent. L'accès au rapport demande une authentification Microsoft.

Q72 L'application est-elle rapide ?

PROBABLE

Oui : les modèles sont chargés une fois au démarrage et une recommandation revient à calculer 45 scores (un par destination), ce qui est quasi instantané. Aucun réentraînement n'a lieu dans l'application.

THÈME 10

Architecture, conception et technologies

5 questions

Q73 Décrivez l'architecture logique.

PROBABLE

Cinq couches : les données de l'agence ; la préparation (nettoyage, variables) ; l'intelligence (moteur de recommandation, segmentation) ; la restitution (modèle en étoile, indicateurs, Power BI) ; la présentation (application TravelBI). Chaque couche enrichit la précédente et peut évoluer indépendamment.

Q74 Décrivez l'architecture physique.

PROBABLE

Trois nœuds : le poste d'analyse, où le notebook (Google Colab) prépare les données et entraîne les modèles ; Power BI Service, qui héberge le rapport publié ; le poste de l'agence, où TravelBI calcule localement indicateurs et recommandations et affiche le rapport par HTTPS.

Q75 Commentez votre diagramme de classes.

PROBABLE

Il sépare trois responsabilités. L'interface : MainWindow compose cinq pages (DashboardPage, ReportsPage, RecoPage, ModelsPage, AboutPage). Le moteur : RecommenderEngine charge les artefacts, calcule et explique les recommandations. Les indicateurs : un module indépendant qui calcule les KPI. Le calcul ne dépend pas de l'interface, ce qui permet de le tester seul.

Q76 Quels sont les acteurs de votre diagramme de cas d'utilisation ?

PROBABLE

Le directeur, qui consulte le tableau de bord, les rapports et la performance des modèles ; le conseiller commercial, qui recommande pour un client existant ou nouveau et exporte les résultats ; l'analyste de données, qui prépare les données, entraîne les modèles, publie le rapport et vérifie la cohérence ; et Power BI Service comme acteur système.

Q77 Pourquoi ces technologies ?

PROBABLE

Python pour son écosystème de science des données ; scikit-learn, LightGBM, XGBoost et CatBoost, références reconnues pour les données tabulaires ; Power BI pour le décisionnel ; PyQt6 pour une interface de bureau soignée ; PyInstaller pour produire un exécutable autonome. Tous sont gratuits ou peu coûteux, ce qui convient à une petite agence.

THÈME 11

Sécurité, éthique et données personnelles

4 questions

Q78 Comment protégez-vous les données personnelles des clients ?

TRÈS PROBABLE

Les données restent sur les postes de l'agence : l'application fonctionne en local. Le rapport publié n'est accessible qu'après authentification Microsoft. Pour une mise en production, il faudrait pseudonymiser les identifiants, limiter les colonnes exportées et contrôler l'accès aux postes, conformément à la loi organique tunisienne n° 2004-63 sur la protection des données personnelles.

Q79 Votre ancienne présentation parlait du RGPD. Est-il applicable ?

QUESTION PIÈGE

Le cadre applicable en Tunisie est la loi organique n° 2004-63 du 27 juillet 2004, sous le contrôle de l'INPDP. Le RGPD européen ne s'appliquerait qu'en cas de traitement de données de résidents de l'Union européenne.

Q80 Votre moteur peut-il être biaisé ou injuste ?

PROBABLE

Il présente un biais de popularité : avec un poids de 30 %, il tend à recommander les destinations déjà populaires, au détriment de la diversité. Il utilise aussi le revenu et l'âge du client. Ce n'est pas discriminant dans ce contexte, mais il faudrait mesurer la diversité et la couverture du catalogue et veiller à ne pas exclure systématiquement certains profils.

Q81 Et si un conseiller suit aveuglément le moteur ?

PROBABLE

Le moteur est une aide à la décision, pas un remplaçant. L'explication fournie avec chaque proposition permet au conseiller de la vérifier et de l'adapter ; il garde la décision finale.

THÈME 12

Limites, perspectives et bilan

6 questions

Q82 Quelles sont les principales limites de votre travail ?

TRÈS PROBABLE

Les données majoritairement générées, qui limitent la portée des résultats ; les départs futurs dans les données ; le biais de sélection et la fuite d'information dans l'évaluation ; le signal collaboratif inexploité ; l'anomalie des visuels par canal dans Power BI ; l'absence d'évaluation en conditions réelles.

Q83 Quelles sont vos perspectives ?

TRÈS PROBABLE

D'abord corriger le protocole d'évaluation et brancher le système sur l'historique réel de l'agence pour confirmer les performances. Ensuite, mesurer l'impact commercial par le taux de conversion puis un test A/B. Enfin, enrichir le conseil (prix des vols en temps réel, avis clients) et proposer les recommandations en ligne sur les canaux de l'agence.

Q84 Si vous deviez refaire le projet, que changeriez-vous ?

PROBABLE

Je mettrais en place dès le départ un protocole d'évaluation en trois parties et je calculerais les variables après le découpage. Je construirais les visuels Power BI uniquement sur des mesures DAX, et je collecterais plus tôt l'historique réel de l'agence.

Q85 Qu'avez-vous appris personnellement ?

PROBABLE

À mener un projet de données de bout en bout, de la compréhension d'un métier à la livraison d'un outil utilisable ; à comparer rigoureusement des modèles avec des métriques adaptées ; et surtout à examiner mes propres résultats de façon critique, à en identifier les biais et à les exposer honnêtement.

Q86 Votre solution est-elle réellement utilisée par l'agence ?

PROBABLE

Elle est opérationnelle et livrée sous forme d'exécutable. Son usage réel dépend de son alimentation avec l'historique complet de l'agence, qui est la prochaine étape.

Conseil : Répondez selon la réalité : si l'agence l'a testée, dites-le avec des exemples.

Q87 Qu'est-ce qui distingue votre projet d'un simple tutoriel de recommandation ?

QUESTION PIÈGE

L'adaptation à un vrai contexte d'agence (démarrage à froid, explicabilité, fonctionnement hors ligne), l'intégration du décisionnel et de l'IA dans un même outil, une factorisation matricielle implémentée à la main, la comparaison rigoureuse de sept variantes, le contrôle automatique de cohérence entre notebook et application, et une analyse critique de mon propre protocole.